

Projekt z modelowania stochastycznego – example 4.15

Wiktor Stec, Marcin Rypuła, Aleksy Bałaziński

1 Teoria błędzenia losowego

1.1 Wprowadzenie do błędzenia losowego

Błądzenie losowe (random walk) jest jednym z podstawowych przykładów łańcucha Markowa. Model opisuje proces poruszający się po zbiorze liczb całkowitych, który w każdym kroku wykonuje ruch o jednostkę w prawo lub w lewo z danym prawdopodobieństwem.

Przykładowe interpretacje to ruch pijanego człowieka po prostej albo kapitał gracza, który w każdej rozgrywce wygrywa lub przegrywa jednostkę.

Proces ten stanowi klasyczny model wykorzystywany w teorii prawdopodobieństwa, statystyce, fizyce i finansach.

1.2 Definicja modelu

Rozważamy łańcuch Markowa o przestrzeni stanów

$$S = \{\dots, -2, -1, 0, 1, 2, \dots\}.$$

Prawdopodobieństwa przejścia mają postać

$$P_{i,i+1} = p, \quad P_{i,i-1} = 1 - p, \quad 0 < p < 1.$$

Oznacza to, że niezależnie od aktualnego stanu:

- z prawdopodobieństwem p następuje ruch o jeden krok w prawo,
- z prawdopodobieństwem $1 - p$ następuje ruch o jeden krok w lewo.

Model jest jednorodnym czasowo łańcuchem Markowa, ponieważ prawdopodobieństwa przejścia nie zależą od czasu.

Poszczególne ścieżki spaceru losowego przedstawia Rys. 1.

1.3 Komunikacja stanów i nierozkładalność

Jednym z podstawowych pojęć w teorii łańcuchów Markowa jest komunikacja stanów. Mówimy, że stan j jest osiągalny ze stanu i , jeśli istnieje skończona liczba kroków n , taka że prawdopodobieństwo przejścia ze stanu i do stanu j w dokładnie n krokach jest dodatnie, czyli

$$P_{i,j}^{(n)} > 0.$$


Jeżeli stan i jest osiągalny ze stanu j oraz jednocześnie stan j jest osiągalny ze stanu i , to mówimy, że stany komunikują się.

W analizowanym modelu komunikacja stanów wygląda następująco:


- jeśli $j > i$, wystarczy wykonać odpowiednią liczbę ruchów w prawo,
- jeśli $j < i$, wystarczy wykonać odpowiednią liczbę ruchów w lewo.

Ponieważ prawdopodobieństwa przejścia w obu kierunkach są dodatnie ($0 < p < 1$), każda taka ścieżka ma dodatnie prawdopodobieństwo realizacji. Oznacza to, że każdy stan komunikuje się z każdym innym stanem. Łańcuch posiada zatem tylko jedną klasę komunikującą się i jest nierozkładalny.


Nierozkładalność jest bardzo istotną własnością, ponieważ pozwala klasyfikować cały łańcuch na podstawie pojedynczego stanu. W ogólnym przypadku różne stany łańcucha mogą mieć różny charakter: część może być rekurencyjna, a część przejściowa. Jednak dla łańcuchów nierozkładalnych zachodzi



(a) $p = 0.4$



(b) $p = 0.6$



(c) $p = 0.5$

Rysunek 1: Ścieżki spaceru losowego dla różnych wartości p .

następujące twierdzenie:

Wszystkie stany należące do tej samej klasy komunikującej się mają ten sam charakter. Oznacza to, że są albo wszystkie rekurencyjne, albo wszystkie przejściowe.

Intuicyjnie wynika to z faktu, że skoro można przechodzić pomiędzy stanami w obie strony, to zachowanie procesu obserwowane w jednym stanie musi odzwierciedlać zachowanie całej klasy stanów. Gdyby jeden stan był rekurencyjny, a drugi przejściowy, prowadziłoby to do sprzeczności z możliwością wielokrotnego przemieszczania się między nimi. W konsekwencji do zbadania własności całego analizowanego błędzenia losowego wystarczy przeanalizować tylko jeden stan, najwygodniej stan początkowy 0. Jeżeli stan 0 okaże się rekurencyjny, to rekurencyjne będą wszystkie stany. Jeżeli natomiast stan 0 będzie przejściowy, to przejściowy będzie cały łańcuch.

1.4 Rekurencyjność i przejściowość stanów

Jednym z podstawowych problemów w teorii łańcuchów Markowa jest określenie, czy proces ma tendencję do powracania do wcześniej odwiedzonych stanów, czy też stopniowo oddala się od nich. W tym celu wprowadza się pojęcia rekurencyjności oraz przejściowości stanów. Interpretacja tych własności jest szczególnie naturalna w przypadku błędzenia losowego. Można bowiem zadać pytanie: jeżeli proces rozpoczyna się w punkcie 0, to czy z pewnością kiedyś do niego powróci, czy też istnieje możliwość, że będzie oddalał się coraz bardziej i nigdy już nie odwiedzi punktu startowego?

Zdefiniujmy zatem stan rekurencyjny:

Niech

$$T_i = \min\{n \geq 1 : X_n = i\}$$

oznacza czas pierwszego powrotu do stanu i . Stan i nazywamy rekurencyjnym, jeżeli po jego opuszczeniu proces powróci do niego z prawdopodobieństwem równym 1. Formalnie

$$P_i(T_i < \infty) = 1.$$

Oznacza to, że powrót do tego stanu jest pewny, chociaż nie wiadomo po jakim czasie on nastąpi. Czas oczekiwania na powrót może być bardzo długi, jednak prawdopodobieństwo, że powrót nastąpi, wynosi 1.

Teraz skupmy się na zdefiniowaniu stanu przejściowego:

Stan i nazywamy przejściowym, jeżeli prawdopodobieństwo powrotu do niego jest mniejsze od 1, czyli

$$P_i(T_i < \infty) < 1.$$

W takim przypadku istnieje dodatnie prawdopodobieństwo, że po opuszczeniu tego stanu proces nigdy już do niego nie wróci. Dla stanu przejściowego możliwe są zatem dwa scenariusze:

- proces wróci do stanu i ,
- proces oddali się od niego na zawsze.

Stan przejściowy nie jest więc odwiedzany nieskończenie wiele razy z prawdopodobieństwem 1.

Po zapoznaniu się z definicjami stanów rekurencyjnego oraz przejściowego można pokusić się o krótką analizę intuicji w kontekście błądzenia losowego. Jeżeli błądzenie jest symetryczne ($p = \frac{1}{2}$), to ruch w lewo i w prawo jest jednakowo prawdopodobny. Nie występuje żaden preferowany kierunek ruchu, dlatego proces stale krąży wokół punktu początkowego. Można oczekiwać, że wcześniej czy później ponownie odwiedzi punkt startowy. Natomiast gdy $p \neq \frac{1}{2}$, pojawia się tendencja do poruszania się w jednym kierunku. Na przykład dla $p > \frac{1}{2}$ ruch w prawo jest bardziej prawdopodobny niż ruch w lewo. W rezultacie proces wykazuje średni dryf w prawo i może oddalić się od punktu początkowego tak bardzo, że już nigdy do niego nie wróci. To właśnie prowadzi do przejściowości stanu.

W teorii łańcuchów Markowa istnieje bardzo użyteczne kryterium pozwalające rozstrzygnąć, czy dany stan jest rekurencyjny czy przejściowy. Niech $P_{ii}^{(n)}$ oznacza prawdopodobieństwo przebywania w stanie i po n krokach przy założeniu, że proces rozpoczął się w stanie i . Wówczas:

- stan i jest rekurencyjny wtedy i tylko wtedy, gdy $\sum_{n=0}^{\infty} P_{ii}^{(n)} = \infty$,
- stan i jest przejściowy wtedy i tylko wtedy, gdy $\sum_{n=0}^{\infty} P_{ii}^{(n)} < \infty$.

Interpretacja tego warunku jest następująca. Suma $\sum_{n=0}^{\infty} P_{ii}^{(n)}$ reprezentuje oczekiwaną liczbę odwiedzin stanu i . Jeżeli suma jest nieskończona, stan będzie odwiedzany wielokrotnie, co odpowiada rekurencyjności. Jeżeli suma jest skończona, liczba odwiedzin jest średnio ograniczona, co oznacza przejściowość.

1.5 Analiza prawdopodobieństwa powrotu do zera

Ponieważ po nieparzystej liczbie kroków nie można wrócić do punktu startowego, $P_{00}^{2n-1} = 0$. Powrót po $2n$ krokach jest możliwy tylko wtedy, gdy:

- wykonano dokładnie n kroków w prawo,
- wykonano dokładnie n kroków w lewo.

Liczba takich ścieżek wynosi $\binom{2n}{n}$. Zatem

$$P_{00}^{2n} = \binom{2n}{n} p^n (1-p)^n.$$

Jest to klasyczny rozkład dwumianowy.

1.6 Zastosowanie wzoru Stirlinga

Do badania zachowania dla dużych n wykorzystuje się przybliżenie Stirlinga o wzorze

$$n! \sim n^{n+\frac{1}{2}} e^{-n} \sqrt{2\pi}.$$

Pozwala ono oszacować współczynnik dwumianowy $\binom{2n}{n} \sim \frac{4^n}{\sqrt{\pi n}}$. Po podstawieniu otrzymujemy asymptotykę

$$P_{00}^{2n} \sim \frac{(4p(1-p))^n}{\sqrt{\pi n}}.$$

1.7 Warunek rekurencyjności

Klasyfikację stanu uzyskuje się badając szereg $\sum_{n=0}^{\infty} P_{00}^n$. W teorii łańcuchów Markowa:

- szereg rozbieżny $\Rightarrow$ stan rekurencyjny,
- szereg zbieżny $\Rightarrow$ stan przejściowy.

Ponieważ $4p(1-p) \leq 1$, a równość zachodzi wyłącznie dla $p = \frac{1}{2}$, otrzymujemy:

- Przypadek symetryczny ($p = \frac{1}{2}$)
- Przypadek niesymetryczny ($p \neq \frac{1}{2}$)

Dla przypadku symetrycznego uzyskujemy $P_{00}^{2n} \sim \frac{1}{\sqrt{\pi n}}$, a szereg $\sum \frac{1}{\sqrt{n}}$ jest rozbieżny. Zatem stan 0 jest rekurencyjny, a więc cały łańcuch jest rekurencyjny. Dla przypadku niesymetrycznego mamy $4p(1-p) < 1$, więc wyrazy maleją wykładniczo i szereg jest zbieżny. Otrzymujemy, że wszystkie stany są przejściowe.


W książce Rossa [2] wyprowadzono również wzór na prawdopodobieństwo powrotu do punktu startowego:

$$P(\text{powrót do } 0) = 2 \min(p, 1-p).$$


W szczególności:

- dla $p = \frac{1}{2}$, $P(\text{powrót do } 0) = 1$, co potwierdza rekurencyjność;
- dla $p \neq \frac{1}{2}$, $P(\text{powrót do } 0) < 1$, co oznacza przejściowość.

Powyższe wyniki ilustruje Rys. 2. Przedstawiono na nim, jak sumy częściowe $\sum_n P_{00}^n$ zależą od n dla różnych wartości p oraz prawdopodobieństwo powrotu do zera w zależności od p .



(a) Wyniki analityczne



(b) Wyniki uzyskane metodą symulacji (5000 ścieżek, 100 kroków spaceru losowego).

Rysunek 2: Sumy częściowe i prawdopodobieństwo powrotu w zależności od p .

1.8 Dwuwymiarowe błądzenie losowe

Rozszerzeniem modelu jest błądzenie na płaszczyźnie. Stan opisuje para (i, j) . W każdym kroku proces przechodzi w lewo, w prawo, w górę i w dół, każde z prawdopodobieństwem $\frac{1}{4}$. Analiza analogiczna do przypadku jednowymiarowego prowadzi do oszacowania

$$P_{00}^{2n} \sim \frac{1}{\pi n}.$$

Ponieważ $\sum_{n=1}^{\infty} \frac{1}{n}$ jest szeregiem rozbieżnym, otrzymujemy konkluzję, że symetryczne błądzenie losowe w dwóch wymiarach jest również rekurencyjne.

2 Zastosowania spaceru losowego

Pomimo prostej definicji błądzenia losowego jest ono jednym z ważniejszych typów łańcuchów Markowa. Jego popularność wynika z faktu, iż wiele zjawisk można opisać jako ciąg losowych zmian zachodzących w czasie. Poniżej omawiamy kilka przykładów zastosowania błądzenia losowego.

2.1 Problem ruiny gracza

Jednym z najpopularniejszych zastosowań spaceru losowego jest problem ruiny gracza, w której rozważamy gracza posiadającego początkowy kapitał równy i . W każdej rundzie wygrywa on jedną jednostkę z prawdopodobieństwem p lub przegrywa jedną jednostkę z prawdopodobieństwem $q = 1 - p$.

Kapitał gracza po n rozgrywkach można opisać wzorem

$$X_n = i + \sum_{k=1}^n \xi_k,$$

gdzie:

$$\xi_k = \begin{cases} 1, & \text{z prawdopodobieństwem } p, \\ -1, & \text{z prawdopodobieństwem } q. \end{cases}$$

Otrzymujemy więc klasyczny spacer losowy na zbiorze liczb całkowitych.

Nasuwa się problem, jak wyznaczyć prawdopodobieństwo bankructwa gracza, innymi słowy osiągnięcia stanu kiedy kapitał gracza jest równy 0.

Jeżeli gracz gra sam to prawdopodobieństwo bankructwa wynosi:

$$P_i = \begin{cases} 1, & q \geq \frac{1}{2} \\ \left(\frac{q}{1-q}\right)^i, & q < \frac{1}{2} \end{cases}$$

Możemy rozszerzyć ten wariant o przeciwnika zaczynającego z kapitałem $N - i$. Który wygrywa jedną jednostką z prawdopodobieństwem q od gracza i traci jedną jednostkę z prawdopodobieństwem p . Wtedy prawdopodobieństwo bankructwa gracza wynosi:

$$P_i = \begin{cases} \frac{N-i}{N}, & p = q = \frac{1}{2} \\ \frac{\left(\frac{q}{p}\right)^i - \left(\frac{q}{p}\right)^N}{1 - \left(\frac{q}{p}\right)^N}, & p \neq q. \end{cases}$$

Model ruiny gracza znajduje zastosowanie w teorii ryzyka, matematyce aktuarialnej oraz analizie wypłacalności przedsiębiorstw i instytucji finansowych.

2.2 Ruchy zwierząt w środowisku

Spacer losowy jest również wykorzystywany przy opisywaniu zachowania organizmów w przestrzeni. W naturalnym środowisku dane zwierzę porusza się na podstawie wielu informacji (zapach, stromość, wielkość zasobów, bliskość do wody itp.) Jednak zwierzę nie zawsze posiada pełen obraz środowiska i do jego przemieszczania wkrada się losowość, której już nie można opisać deterministycznie. Z pomocą przychodzi spacer losowy, którym w dość łatwy sposób można to opisać.

W podstawowym modelu dyskretnym, położenie organizmu po n krokach, oznaczane jako X_n definiuje się za pomocą równania rekurencyjnego:

$$X_n = X_{n-1} + \xi_n$$

W klasycznym wariancie zakłada się, że średnie przesunięcie kwadratowe (MSD) rośnie liniowo z czasem trwania ruchu: $E[X_n^2] = 2dDn$

gdzie d to wymiar rozpatrywanej przestrzeni (np. $d = 2$ dla organizmów poruszających się po przestrzeni dwuwymiarowej), a D to współczynnik dyfuzji charakterystyczny dla danego gatunku i środowiska.

Rzeczywiste zastosowanie: Strategie żerowania i Loty Lévy'ego

Loty Lévy'ego (*Lévy flight*) są szczególnym rodzajem spaceru losowego, w którym większość wykonywanych kroków jest krótka, jednak od czasu do czasu pojawiają się bardzo długie skoki.

W klasycznym spacerze losowym lub ruchu Browna długości kolejnych kroków są zwykle podobnej wielkości. W rezultacie trajektoria procesu wygląda zazwyczaj jak ciąg drobnych ruchów wykonywanych wokół punktu początkowego. Natomiast dla lotu Lévy'ego sytuacja wygląda inaczej. Przez długi czas obiekt wykonuje niewielkie ruchy lokalne, po czym może nagle wykonać bardzo duży skok. Następnie ponownie porusza się lokalnie. W rezultacie trajektoria składa się z wielu krótkich odcinków przeplatanych sporadycznymi, lecz bardzo dużymi przemieszczeniami.

Długości kroków w lotach Lévy'ego pochodzą z rozkładów o grubych ogonach. Oznacza to, że prawdopodobieństwo wystąpienia bardzo dużego kroku maleje znacznie wolniej niż w przypadku rozkładu normalnego.

Typowo zakłada się zależność

$$P(U > u) \sim u^{-\alpha},$$

gdzie:

- U oznacza długość kroku,
- $\alpha \in (0, 2)$ jest parametrem rozkładu.

2.3 Spacer losowy jako narzędzie eksploracji grafu

Spacer losowy na grafie stanowi naturalne połączenie teorii grafów z teorią procesów stochastycznych, a dokładniej z łańcuchami Markowa. Niech $G = (V, E)$ będzie grafem nieskierowanym a $\deg(v) = \#\{u \in V : u, v \in E\}$. Definiujemy proces stochastyczny $(X_t)_{t \geq 0}$ na zbiorze wierzchołków V , taki że:

$$\mathbb{P}(X_{t+1} = v \mid X_t = u) = \begin{cases} \frac{1}{\deg(u)}, & \{u, v\} \in E, \\ 0, & \text{w przeciwnym wypadku.} \end{cases}$$

Powyższy proces można zapisać jako macierz P , gdzie element $P_{u,v}$ określa prawdopodobieństwo przejścia ze stanu u do v .

2.3.1 Zmienne losowe czasu

- **Czas pierwszego przejścia** do wierzchołka v , oznaczany jako T_v , to zmienna losowa zdefiniowana jako:

$$T_v = \min\{t \geq 0 : X_t = v\}$$

- **Czas pokrycia** dla trajektorii procesu, oznaczany jako T_{cov} , to moment, w którym zbiór odwiedzonych wierzchołków staje się równy całemu zbiorowi V :

$$T_{cov} = \min\{t \geq 0 : \{X_0, X_1, \dots, X_t\} = V\}$$

2.3.2 Struktura grafu poprzez własności czasowe procesu

Poprzez spacer losowy możemy wnioskować o właściwościach danego grafu. Przykładowo:

- **Czas dojścia** $H_{u,v}$ - jest to oczekiwana liczba kroków potrzebna aby spacer losowy rozpoczynający w wierzchołku u po raz pierwszy odwiedził wierzchołek v :

$$H_{u,v} = \mathbb{E}_u[T_v]$$

- **Oczekiwana wartość pokrycia całego grafu** C_G - jest to maksymalna liczba oczekiwanych kroków potrzebna do odwiedzenia wszystkich wierzchołków grafu startując z "najgorszego" wierzchołka, czyli takiego z którego, najtrudniej odwiedzić wszystkie pozostałe wierzchołki:

$$C_G = \max_{u \in V} \mathbb{E}_u[T_{cov}]$$

Dzięki powyższym narzędziom można analizować strukturę grafu za pomocą metod probabilistycznych.

2.3.3 Rozkład stacjonarny wierzchołków

Jeżeli graf G jest spójny, nieskierowany, nie jest dwudzielny, spacer losowy tworzy **ergodyczny łańcuch Markowa**. Stan ten opisuje **rozkład stacjonarny** π , spełniający równania równowagi:

$$\pi(u)P_{u,v} = \pi(v)P_{v,u}$$

zatem:

$$P_{u,v} = \frac{1}{\deg(u)}$$

Szukamy rozkładu stacjonarnego π , spełniającego równanie

$$\pi = \pi P,$$

co równoważnie oznacza, że dla każdego $v \in V$ zachodzi

$$\pi(v) = \sum_{u \in V} \pi(u)P_{u,v}$$

$$\pi(v) = \sum_{u: \{u,v\} \in E} \pi(u) \frac{1}{\deg(u)}$$

Zakładamy, że rozwiązanie ma postać proporcjonalną do stopnia wierzchołka:

$$\pi(v) = C \cdot \deg(v)$$

gdzie C jest stałą normalizacyjną.

Podstawiając do równania stacjonarności otrzymujemy

$$\sum_{u: \{u,v\} \in E} \pi(u) \frac{1}{\deg(u)} = \sum_{u: \{u,v\} \in E} \frac{C \deg(u)}{\deg(u)}$$

Po skróceniu otrzymujemy

$$\sum_{u: \{u,v\} \in E} C = C \cdot \deg(v)$$

Zatem warunek stacjonarności jest spełniony.

Korzystając z normalizacji rozkładu:

$$\sum_{v \in V} \pi(v) = 1$$

Podstawiając $\pi(v) = C \deg(v)$, mamy

$$\sum_{v \in V} C \deg(v) = 1$$

$$C \sum_{v \in V} \deg(v) = 1$$

Korzystając z faktu, że w grafie nieskierowanym zachodzi

$$\sum_{v \in V} \deg(v) = 2|E|$$

otrzymujemy

$$C = \frac{1}{2|E|}$$

W konsekwencji dostajemy końcowy wzór na rozkład stacjonarny:

$$\pi(v) = \frac{\deg(v)}{2|E|} \implies \pi(v) \propto \deg(v)$$

Dowodzi to, że wierzchołki o wyższym stopniu są asymptotycznie odwiedzane proporcjonalnie częściej.

2.3.4 Wnioski

Poprzez wprowadzenie spaceru losowego do teorii grafów możemy badać wiele różnych problemów związanych z grafami za pomocą metod probabilistycznych, które mogą okazać się w niektórych przypadkach bardziej efektywne niż metody kombinatoryczne lub deterministyczne.

3 Zastosowanie symulacji: równanie przewodnictwa cieplnego

Interesujące zastosowanie spaceru losowego przedstawione jest w [1]. Wzorując się na opracowaniu Lawlera pokażemy, jak za pomocą symulacji otrzymać przybliżone rozwiązania równania przewodnictwa cieplnego.

Niech $p_n(x)$ oznacza średnią gęstość „cząsteczek ciepła” w punkcie x w chwili n . Cząstki przemieszczają się losowo i w zależności od wymiaru przestrzeni d w każdym kroku cząstka może się przemieścić w jednym z d kierunków. Na przykład, jeśli $d = 2$, z prawdopodobieństwem $1/4$ cząstka może przemieścić się w prawo, lewo, górę lub w dół. Dodatkowo zakładamy, że cząstki są od siebie niezależne. Rozważmy jak zmienia się gęstość w punkcie x . Przy naszych założeniach, średnio $1/(2d)$ cząstek znajdujących się w każdym z sąsiadujących punktów y przemieści się do x , a zatem mamy

$$p_{n+1}(x) = \frac{1}{2d} \sum_{\|y-x\|=1} p_n(y). \quad (1)$$

Skończony obszar, na którym mogą przemieszczać się cząstki oznaczamy przez $A \subset \mathbf{Z}^d$. Granicę tego obszaru oznaczamy jako $\partial A = \{z \in \mathbf{Z}^d \setminus A : \text{dist}(z, A) = 1\}$. Definiujemy również dwa operatory liniowe $\mathcal{Q}$ i $\mathcal{L}$ jako

$$\begin{aligned} \mathcal{Q}F(x) &= \frac{1}{2d} \sum_{\|y-x\|=1} F(y), \\ \mathcal{L}F(x) &= \frac{1}{2d} \sum_{\|y-x\|=1} (F(y) - F(x)) = (\mathcal{Q} - I)F(x). \end{aligned}$$

Zauważmy, że każda funkcja $F : A \rightarrow \mathbf{R}$ może być rozumiana jako wektor w $\mathbf{R}^{|A|}$, zatem $\mathcal{Q}$ i $\mathcal{L}$ możemy traktować jak macierze $|A| \times |A|$. Wówczas (1) możemy zapisać jako

$$\partial_n p_n(x) = \mathcal{L}p_n(x), \quad x \in A, \quad (2)$$

gdzie $\partial_n p_n(x) = p_{n+1}(x) - p_n(x)$. Równanie (2) jest dyskretną wersją równania przewodnictwa cieplnego, gdzie $\mathcal{L}$ jest dyskretnym operatorem Laplace'a.

Zakładamy, że temperatura na brzegu obszaru jest równa zero, tj. $p_n(x) = 0$ dla $x \in \partial A$. Odpowiada to sytuacji, w której cząsteczki są eliminowane podczas opuszczania obszaru A . W chwili początkowej rozkład temperatury jest dany: $p_0(x) = f(x)$.

Na początek założmy, że $d = 1$ i $A = \{1, \dots, N-1\}$. Równanie (2) rozwiązujemy metodą rozdzielania zmiennych, tj. zakładamy, że rozwiązanie ma postać iloczynu $p_n(x) = \lambda^n \phi(x)$. Wówczas $\partial_n p_n(x) = (\lambda - 1)p_n(x)$ i z (2) dostajemy

$$(\lambda - 1)\lambda^n \phi(x) = \lambda^n (\mathcal{Q} - I)\phi(x) \rightarrow \mathcal{Q}\phi(x) = \lambda\phi(x).$$

Zatem szukamy wartości i wektorów własnych $\mathcal{Q}$, przy czym wymagamy $\phi = 0$ na $\partial A = \{0, N\}$. Za-uważmy, że

$$\mathcal{Q} \sin(\theta x) = \frac{1}{2}(\sin \theta(x-1) + \sin \theta(x+1)) = \cos \theta \sin \theta x.$$

Jeśli weźmiemy $\theta_j = \pi j/N$ to dostaniemy wektory i wartości własne $\mathcal{Q}$ równe odpowiednio

$$\phi_j(x) = \sin\left(\frac{\pi j x}{N}\right), \quad \lambda_j = \cos\left(\frac{\pi j}{N}\right),$$

dla których to ϕ_j jest spełniony warunek $\phi_j(0) = \phi_j(N) = 0$. Dodatkowo $\{\phi_j\}$ są ortogonalne, bowiem

$$\langle \phi_i, \phi_j \rangle = \sum_{x=1}^{N-1} \sin\left(\frac{\pi i x}{N}\right) \sin\left(\frac{\pi j x}{N}\right) = \frac{N}{2} \delta_{ij}.$$

Zatem każdą funkcję f na A możemy zapisać jednoznacznie w postaci

$$f(x) = \sum_{j=1}^{N-1} c_j \phi_j(x).$$

Tak więc wystarczy, że znajdziemy c_j takie, że $p_0(x) = f(x) = \sum_j c_j \phi_j(x)$. Wówczas rozwiązaniem (2) przy określonych warunkach początkowych będzie

$$p_n(x) = \sum_{j=1}^{N-1} c_j \lambda_j^n \phi_j(x).$$

Jako prosty przykład weźmy

$$f(x) = \delta_{x_0}(x) \equiv \begin{cases} 1 & \text{jeśli } x = x_0 \\ 0 & \text{w p.p.} \end{cases}.$$

Wówczas

$$\sum_{x=1}^{N-1} f(x) \phi_i(x) = \sum_{x=1}^{N-1} \sum_{j=1}^{N-1} c_j \phi_j(x) \phi_i(x) = \sum_{j=1}^{N-1} c_j \langle \phi_i, \phi_j \rangle = \frac{N}{2} c_i.$$

Z definicji f po lewej stronie powyższego mamy $f(x_0) \phi_i(x_0) = \phi_i(x_0)$, a stąd

$$c_i = \frac{2}{N} \phi_i(x_0) = \frac{2}{N} \sin\left(\frac{\pi i x_0}{N}\right).$$


Zatem analityczne rozwiązanie (2) w tym przypadku to

$$p_n(x) = \frac{2}{N} \sum_{j=1}^{N-1} \sin\left(\frac{\pi j x_0}{N}\right) \cos\left(\frac{j\pi}{N}\right)^n \sin\left(\frac{\pi j x}{N}\right).$$

Porównanie rozwiązanie analitycznego z symulacją dla różnych kroków czasowych zilustrowane jest na Rys. 3. Symulację wykonano z użyciem 10000 cząstek. Jak możemy zobaczyć na rysunku, wyniki uzyskane metodą symulacji są bardzo dobrym przybliżeniem rozwiązania analitycznego. Możemy również zaobserwować, że ze względu na zerową temperaturę na brzegu obszaru A , układ stopniowo wygasa (temperatura na A zmniejsza się) przy czym przyjmuje ona największe wartości na środku obszaru.

Korzystając z analogicznych metod można pokazać, że w przypadku dwuwymiarowym

$$\lambda_{\mathbf{k}} = \frac{1}{2} \left[\cos\left(\frac{k_1 \pi}{N_1}\right) + \cos\left(\frac{k_2 \pi}{N_2}\right) \right],$$



Rysunek 3: Ewolucja układu z jednym źródłem.

$$\phi_{\mathbf{k}}(x_1, x_2) = \sin\left(\frac{k_1 \pi x_1}{N_1}\right) \sin\left(\frac{k_2 \pi x_2}{N_2}\right),$$

a rozwiązaniem (2) jest

$$p_n(x_1, x_2) = \sum_{k_1=1}^{N_1-1} \sum_{k_2=1}^{N_2-1} c_{\mathbf{k}} \lambda_{\mathbf{k}}^n \phi_{\mathbf{k}}(x_1, x_2),$$

gdzie

$$c_{\mathbf{k}} = \frac{4}{N_1 N_2} \sum_{x_1=1}^{N_1-1} \sum_{x_2=1}^{N_2-1} f(x_1, x_2) \phi_{\mathbf{k}}(x_1, x_2).$$

Rozważmy najprostszy przykład, gdzie $f(x) = \delta_{\mathbf{x}_0}(x)$. Wówczas


$$c_{\mathbf{k}} = \frac{4}{N_1 N_2} \phi_{\mathbf{k}}(\mathbf{x}_0).$$

Porównanie rozwiązania analitycznego z symulacją przedstawione jest na Rys. 4. Na rysunku widzimy, że podobnie jak w przypadku jednowymiarowym (por. Rys. 3) temperatura „rozchodzi się” stopniowo po całym obszarze. Trzecia mapa cieplna w każdym rzędzie przedstawia różnicę między symulacją a rozwiązaniem dokładnym dla każdego punktu.


Dzięki metodzie symulacyjnej możemy otrzymać przybliżone rozwiązania równania (2) nawet dla bardzo skomplikowanych warunków początkowych. Przykładowe zastosowanie przedstawia Rys. 5.

Literatura


- [1] Gregory F. Lawler. Random walk and the heat equation. University of Chicago, Department of Mathematics Lecture Notes, 2010.
- [2] Sheldon M. Ross. *Introduction to Probability Models*. Academic Press, Burlington, Massachusetts, 9th edition, 2007.



(a) $n = 0$




(b) $n = 5$



(c) $n = 50$

Rysunek 4: Ewolucja układu w dwu wymiarach. Porównanie rozwiązania analitycznego z symulacją.



Rysunek 5: Symulacja ewolucji systemu dla bardziej skomplikowanych warunków początkowych.